

# Vizualizace regulárních výrazů

Regular Expression Visualization

Dominik Kundra

Bakalářská práce

Vedoucí práce: Ing. Jakub Beránek

Ostrava, 2024

# Zadání bakalářské práce

Student:

**Dominik Kundra**

Studijní program:

B0613A140014 Informatika

Téma:

Vizualizace regulárních výrazů  
Regular Expression Visualization

Jazyk vypracování:

čeština

Zásady pro vypracování:

Cílem práce je vytvořit nástroj sloužící pro vizualizaci a ladění regulárních výrazů. Nástroj by měl být schopný zpracovat zvolený regulární výraz, sestavit plán vykonávání daného výrazu dle zvolené implementace a poté umožnit programátorovi interaktivně krokovat provádění regulárního výrazu. Nástroj by měl být vytvořen jako rozšíření do vývojového prostředí (např. do Visual Studio Code), aby šel jednoduše použít při vývoji programů. Výsledná aplikace by měla být řádně zdokumentována a při jejím vývoji by měl být využit verzovací systém (např. git).

1. Analyzujte a popište možnosti implementace regulárních výrazů.
2. Navrhnete architekturu rozšíření do vývojového prostředí, které bude schopné analyzovat regulární výrazy ze zvoleného zdrojového kódu.
3. Naimplementujte nástroj pro vizualizaci regulárního výrazu a integrujte jej do vývojového prostředí.
4. Otestujte vizualizaci nástroje na regulárních výrazech z reálných projektů.

Seznam doporučené odborné literatury:

- [1] FRIELD, Jeffrey. Mastering Regular Expressions 3rd Edition. 2006. O'Reilly Media. ISBN: 978-0596528126
- [2] SORVA, Juha. Visual program simulation in introductory programming education. Espoo: Aalto Univ. School of Science, 2012. ISBN 9789526046266. Dostupný také z WWW: <http://doi.acm.org/10.1145/2445196.2445368>.
- [3] VANDERKAM, Dan. Effective TypeScript : 62 Specific Ways to Improve Your TypeScript. O'Reilly Media, 2019. ISBN 978-1492053699

Formální náležitosti a rozsah bakalářské práce stanoví pokyny pro vypracování zveřejněné na webových stránkách fakulty.

Vedoucí bakalářské práce: **Ing. Jakub Beránek**

Datum zadání: 01.09.2023

Datum odevzdání: 30.04.2024

Garant studijního programu: doc. Mgr. Miloš Kudělka, Ph.D.

V IS EDISON zadáno: 09.11.2023 15:43:31

## **Abstrakt**

No Czech or Slovak abstract is given

## **Klíčová slova**

No Czech or Slovak keywords are given

## **Abstract**

No English abstract is given

## **Keywords**

No English keywords are given

# Obsah

Seznam použitých symbolů a zkratek	5
Seznam obrázků	6
Seznam zdrojových kódů	7
1 Úvod	8
2 Principy a historie regulárních výrazů	10
2.1 Formální jazyk . . . . .	10
2.2 Konečný automat . . . . .	10
2.3 Bezkontextová gramatika . . . . .	11
2.4 Vznik, implementace a vzory . . . . .	12
3 Architektura aplikace	15
3.1 Zvolené návrhy . . . . .	15
3.2 Použité technologie . . . . .	17
4 Knihovna pro práci s regulárními výrazy	20
4.1 Rozvržení a realizace . . . . .	20
Literatura	23
Přílohy	23

# Seznam použitých zkratek a symbolů

AST	– Abstraktní syntaktický strom
NKA	– Nedeterministický konečný automat
DKA	– Deterministický konečný automat
TS	– TypeScript
JS	– JavaScript
Regex	– Regulární výraz (Regular expression)
API	– Aplikační rozhraní
HTML	– HyperText Markup Language

# Seznam obrázků

2.1	Příklad deterministického automatu přijímající slova obsahující písmena z abecedy {a, b} končící písmenem a . . . . .	11
2.2	Příklad nedeterministického automatu ekvivalentního k předchozímu deterministickému	11
2.3	Převedený prázdný výraz $\epsilon$ . . . . .	13
2.4	Převedený výraz <b>a</b> . . . . .	13
2.5	Převedený výraz <b>s t</b> . . . . .	13
3.1	Struktura knihoven aplikace . . . . .	16
3.2	Příklad výsledné JSON struktury regulárního výrazu <b>a+</b> . . . . .	17
4.1	Třídní diagram části knihovny pro práci s regulárními výrazy . . . . .	21

# Seznam zdrojových kódů

3.1	Příklad použití knihovny threads.js . . . . .	18
3.2	Příklad použití web workeru a posílání zpráv . . . . .	19

# Kapitola 1

## Úvod

Vyhledávání v textu patří mezi základní problémy, se kterými se velice pravděpodobně potká skoro každý programátor. Tento problém se dá řešit mnoha způsoby, avšak ne všechna řešení lze použít univerzálně a každý ze způsobů má své výhody a nevýhody. Jedním ze přístupů je využití **regulárních výrazů**. Jedná se o sadu znaků, které nám umožňují nadefinovat výraz a ten je následně převedený do nějaké struktury. Nejčasteji jejich výsledná forma je nějaký **konečný automat**, které jsou blíže vysvětleny v kapitole 2, sekci 2.2. Téměř každý dnešní programovací jazyk je obsahuje, ale jejich implementace se mohou lišit.

Cílem této práce je naimplementovat nástroj, který bude schopný procházet regulární výrazy a následně vizualizovat tyto průchody, jako rozšíření do zvoleného vývojového prostředí.

Při vývoji programů, je programátor často obeznámen s regulárními výrazy, jedná se totiž o poměrně rychlé řešení pro vyhledávání v textu. Můžeme se s nimi setkat, v podstatě skoro ve všech částech softwaru<sup>1</sup>, např. validace formulářů, vyhledávání v textu nebo třeba v příkazovém řádku. Avšak tyto výrazy se brzy mohou stát hůře čitelnými, jelikož neumožňují v podstatě skoro žádné formátování<sup>2</sup>. Taktéž mohou být pro mnoho lidí matoucí, či nepřehledné. Z tohoto důvodu se hodí mít nástroj, který potencionálně usnadní práci programátorům, tak aby si mohli zobrazit průchod zadaným výrazem. Dále pro lidi, kteří například vidí tyto výrazy poprvé v životě může být snazší jim porozumět, je-li jim ukázáno jak fungují v jednotlivých krocích. Sice již existují řešení tohoto problému a to v různých formách [1, 2, 3], ale pro zvolené vývojové prostředí mnoho přístupů neexistuje. Tato situace je motivací, zabývat se problémem do hloubky a pokusit se nabídnout originální řešení v daném směru, které by mohlo být přínosem pro ostatní.

Implementace těchto výrazů bývá nejčasteji formou konečných automatů, jedná se o poměrně výkonné řešení. Abychom tohoto dosáhli musíme převést jejich textovou formu na naší chtěnou.

---

<sup>1</sup>počítačový program, aplikace

<sup>2</sup>upravení vzhledu, tvaru



To může být například využitím, bezkontextové gramatiky<sup>3</sup> nebo vlastní implementací parsování<sup>4</sup>. Později v kapitole 3 je vysvětleno, který ze způsobů byl zvolen a proč.

Vyzualizaci regulárních výrazů můžeme chápat několika způsoby, lze si představit například zobrazení ekvivalentního konečného automatu. Další možný přístup je pomocí mapování stavů automatu do původní textové formy. Toto může být obtížné, jelikož je třeba si pamatovat nějaký vztah, mezi původním textem a formou konečného automatu. Druhý přístup byl zvolený pro tuto práci a to ve smyslu **krokovacího nástroje (debugger)**. Krokování pak funguje, jako historie průchodu zadaným výrazem. Krokování je známé v programovacích prostředích jako debugger, typicky určený pro hledání chyb ve zdrojovém kódu.

Regulární výrazy pocházejí z **teoretické informatiky**<sup>5</sup>, byly nadefinovány roku 1956, ale k jejich využití v počítačích se dostalo až v roce 1968 v operačním systému **UNIX**. Od své původní formy se dnes ve svém základu téměř neliší, ale často již obsahují složitější funkcionality a rozšířenou syntaxi. Jedno z jejich nejznámějších využití je v příkazovém řádku v linuxových operačních systémech, původně v UNIXu a to pod názvem **g/re/p** nebo-li **grep** “Global search for Regular Expression and Print matching lines”[4].

Výsledkem této práce, je možnost procházet základní regulární výrazy ve zvoleném vývojovém prostředí. Jelikož jsou dnešní implementace velice mohutné a poskytují mnoho funkcionalit, tak není prakticky možné se zabývat celou problematikou v této práci. Proto byly vybrány prvky, které se dají obecně považovat za důležité. Těmito prvky jsou například **znaky**, **iterace**, **výběr** a **skupiny**.

V kapitole 2 jsou podrobněji popsány pojmy z teoretické informatiky, dále implementace regulárních výrazů, jejich vzory a vznik. Následně v kapitole 3 se dozvíte, jaké technologie jsou využívány a o architektuře použité v této práci. Kapitola 4 se zabývá implementací knihovny pro zpracování regulárních výrazů. Ta je pak využita v samotné vizualizaci.

---

<sup>3</sup>formální jazyk, který analyzuje a zpracovává textový řetězec

<sup>4</sup>proces kompilace a interpretace

<sup>5</sup>vědní obor na pomezí mezi informatikou a matematikou

## Kapitola 2

# Principy a historie regulárních výrazů

Tato kapitola se zabývá definicí regulárních výrazů, jak fungují a jak se jednotlivé implementace mohou lišit. Součástí jejich implementace, provází několik pojmů z teoretické informatiky, odkud pocházejí. Hlavně se jedná o **Konečné automaty** a **Thompsonovo sestrojení**.

### 2.1 Formální jazyk

Formální jazyk je libovolná množina koečných slov nad určitou abecedou. Slova chápeme jako řetězece znaků, která jsou přijímaná zadaným jazykem. Tato slova musí být sice konečná ale množina těchto slov může být nekonečná. Tyto jazyky mohou být definovány regulárními výrazy, formální gramatikou, konečnými automaty a dalšími. Regulární jazyky jsou pak jednou z možných definic formálních jazyků.


### 2.2 Konečný automat

Ve spojení s regulárními výrazy se často pojí konečné automaty, jedná se o další oblast v teoretické informatice. Tato práce implementuje regulární výrazy právě ve formě konečných automatů.


Zjednodušeně se dá říct, že konečný automat je model jednoduchého počítače, který má určitý počet stavů a přechodů [5].

Stavy jsou typicky zakreslovány jako kružnice, a každý automat musí obstarávat alespoň jeden počáteční stav, ale může jich také obsahovat více. To samé platí pro konečný/é stav/y. Konečné stavy se také vyznačují jako kruh, ale z dvojťou čarou. Počáteční stavy, jsou označovány jako stav, do kterého vede šipka, která ale nevychází z jiného stavu. Přechody jsou pak šipky vedoucí z jednoho stavu do druhého, jsou označeny přechodovým symbolem. Avšak přechod může odkazovat na stejný stav, ze kterého vychází. Tyto přechody nám říkají že pokud chceme přejít z jednoho stavu do druhého, tak musíme v přijímaném slově se posunout o daný symbol. Pokud to není možné, tak nemůžeme přejít do tohoto stavu.

Tyto automaty se dělí na **deterministické** a **nedeterministické**, zkráceně **DKA** (deterministický konečný automat) a **NKA** (nedeterministický konečný automat). DKA mohou mít v daném stavu pro každý znak abecedy **maximálně** jeden přechod, dále **nemohou obsahovat tzv. prázdný znak** často označovaný řeckým písmenem epsilon  $\epsilon$ . Příklad tohoto automatu je možno vidět na obrázku 2.1. NKA naopak obojí umožňují. Prázdné znaky slouží pro změnu stavu bez změny aktuální pozice v hledaném slově. Pro ukázkou si můžeme porovnat dva ekvivalentní konečné automaty, NKA na obrázku 2.2 a DKA na obrázku 2.1. Nakonec je dobré podotknout, že každý NKA lze převést na ekvivalentní DKA.



Obrázek 2.1: Příklad deterministického automatu přijímající slova obsahující písmena z abecedy  $\{a, b\}$  končící písmenem  $a$



Obrázek 2.2: Příklad nedeterministického automatu ekvivalentního k předchozímu deterministickému

## 2.3 Bezkontextová gramatika

Součástí této práce je i využití Bezkontextové gramatiky a jelikož spadají pod teoretickou informatiku, tak si zkráceně vysvětlíme tuto oblast.

Bezkontextová gramatika, je další z možných definic formálních jazyků. Je určena konečnou množinou **neterminálních symbolů** (proměnných), konečnou množinou **terminálních symbolů**, která nesmí mít žádné prvky společné s předchozí množinou. Dále **počátečním neterminálem** s konečnou množinou **přepisových pravidel**[6].

$$A \longrightarrow \beta$$

kde  $A$  je neterminál a  $\beta$  je řetězec složený z terminálů a/nebo neterminálů. Dále šipka indikuje **přepsání** tj. levá strana se přepisuje na stranu pravou. Konečný generovaný řetězec danou gramatikou, je pouze tvořen terminálními symboly. Aby mohl být řetězec přijímaný zadanou gramatikou, musí ho být schopná tato gramatika vygenerovat.

## 2.4 Vznik, implementace a vzory

Regulární výrazy byly poprvé nadefinovány Americkým matematikem **Stephan Cole Kleene**, jako regulární jazyky. Dále se aplikovali v teoretické informatice, jako podkategorie **teorie automatů** a součást **formálních jazyků**. Ačkoliv byly nadefinovány začátkem padesátých let, tak jejich využití v počítačích nastalo až na konci šedesátých let a to v jedním z nejznámějších operačních systémů UNIX.


### Thompsonovo sestrojení

První kdo navrhnul implementaci používanou v počítačích byl **Ken Thompson**. Principem byl převod regulárního výrazu na NKA. Tato metoda se často používá v podobné či stejné formě doposud. Algoritmus se pojmenoval **Thompson's construction** (Thompsonovo sestrojení), který převádí textovou reprezentaci výrazu na ekvivalentní nedeterministický automat. Toto sestrojení je využito v této práci a blíže jej popisuje následující část textu.

NKA se běžně využívá, jelikož je poměrně jednoduchý na implementaci a také oproti DKA využívá **zpětného krokování (backtracking)** a povoluje složitější operace jako je **rozhlednutí se kolem sebe (lookaround)**. Zpětné krokování je důležité pro NKA, jelikož neexistuje jednoznačná cesta vyhodnocení. DKA mají výhodu že jsou rychlejší, ale jsou typicky větší než jejich ekvivalentní NKA a neumožňují některé složitější operace. Také nepotřebují zpětné krokování, jelikož jejich cesta je deterministická tzn. existuje vždy jen jedna cesta pro hledané slovo. Někdy se ale využívá kombinace DKA i NKA, kdy DKA se využije kvůli vyšší rychlosti vyhledání daného slova a pokud bylo slovo nalezeno, tak se použije NKA pro jejich rozšířené možnosti.


Výsledný NKA po thompsonově sestrojení má právě jeden vstupní a výstupní stav. Thompsonovo sestrojení dále definuje následující pravidla.

Prázdný výraz  $\epsilon$ , je převedený na vstupní stav, přechod  $\epsilon$  a konečný stav. Výsledný konečný automat je na obrázku .




Obrázek 2.3: Převedený prázdný výraz  $\epsilon$

Výraz  $a$ , je převedený podobně jako prázdný výraz, ale s rozdílem přechodu  $a$  místo  $\epsilon$ . Konečný automat, který nám vznikne je ukázán na obrázku 2.4.



Obrázek 2.4: Převedený výraz  $a$

Pro zadaný výraz  $s|t$ , kdy  $s$  je levá strana varianty a  $t$  je pravá strana varianty, platí že ze stavu  $q$  (počáteční stav) vedou dva přechody  $\epsilon$  na počáteční stavy variant  $s$  a  $t$ . Z těchto počátečních stavů dále pokračuje sekvence stavů  $N(s)$  pro  $s$  a  $N(t)$  pro  $t$ . Konce variant  $s$  a  $t$  mají jediný přechod  $\epsilon$  na konečný stav  $f$ . Na obrázku 2.5 je vyobrazen výsledný NKA, kde skupina stavů v zelené části je  $s$  a červená skupina je  $t$ .



Obrázek 2.5: Převedený výraz  $s|t$

Další pravidla pro sestavení lze například najít na anglické wikipedia stránce pro thompsonovo sestavení [7].

## Základní vzory

V Předchozích sekcích, již byly popsány základní konstrukce týkající se regulárních výrazů. Tato sekce se zabývá jejich základními vzory.

Za nejjednodušší výraz lze považovat prázdný výraz, také označovaný jako  $\epsilon$ . Výrazy mohou obsahovat **téměř** libovolný znak, který bude přijímat slova s daným znakem. Avšak nemohou být použity znaky, které jsou rezervované, nebo-li jsou součástí syntaxe regulárních výrazů. Chceme-li použít tyto znaky je potřeba použít znak

. Takový znak se pak nazývá anglicky **escaped character**.

Iterace, je možnost jak lze opakovaně provádět nějakou operaci. Například lze iterovat znak, skupinu a další konstrukce. Prvním typem iterace je **\***, známa jako **Kleene star**, nebo-li kleene hvězda. Tento druh iterace může mít počet opakování od **0** až do **n** iterací, taktéž se nazývá **nula** **nebo více**. Existují další 2 typy iterací a to je iterace typu **jedna nebo více** označována znakem **+** a **iterace v rozmezí**, která se značí {od,do}.

Operace **nebo** je dalším základním vzorem pro regulární výrazy. Jedná se o výběr mezi pravou a levou stranou. Oddělovacím znakem je typicky **|** podobně jako bitová operace **OR** v mnoha programovacích jazycích.

Dalšími základními konstrukty jsou například skupiny, které jsou obaleny v jednoduchých závkách.

## Implementace v programovacích jazycích

Dnes v podstatě každý programovací jazyk má v nějaké formě implementované zpracování regulárních výrazů. Tato implementace se však často liší, sice základ bývá stejný, ale rozšířená syntaxe je často odlišná. Může se tak stát to, že to co je podporované jedním jazykem, není podporované druhým. Taktéž oproti původním regulárním výrazům, dnešní implementace osahují mnohdy složitější koncepce jako je rozhlédnutí se (Anglicky lookaround), nebo například rekurze. Někdy sice jazyky sdílí jednu stejnou funkcionalitu, ale mohou se lišit syntaxí.

Rozhlédnutí se je již celkem pokročilá funkcionalita. Jejím principem je takzvaně, nezachytávání znaků při zpracovávání. Typicky je dělíme podle směru a to na **dopředné** a **zpětné** rozhlédnutí. Pak je dělíme podle podmínění a to na **kladné** a **negativní** rozhlédnutí. Pokud máme kladné podmínění **musí** uzavřený výraz být splněný a pokud máme záporné tak **nesmí** být splněný. V původní formě regulárních výrazů, tato funkce neexistovala.

Mnohdy je potřeba, nalezený řetězec rozdělit do skupin. Tuto možnost dnešní implementace také umožňují. Chceme-li zdůraznit že zadaný podvýraz je skupinou, obalíme ho do závorek. Tato vlastnost je žádaná, jelikož pak nemusíme hledat v již nalezeném řetězci další podřetězce. Dají se dělit na zachytávající (capturing), pojmenované (named) a nezachytávající (non-capturing). Pojmenované patří pod zachytávající, akorát jsou identifikovány pomocí názvu oproti indexu. Poslední druh slouží čistě jako skupina pro regulární výraz, ale ve výsledku se neobjevuje.

## Kapitola 3

# Architektura aplikace

### 3.1 Zvolené návrhy


#### Základní struktura aplikace

Aplikace je členěná na 3 základní knihovny, což je zřejmé na obrázku 3.1. Každá část má vlastní účel a jsou navzájem izolovány. První z těchto knihoven je **regexer**, ta slouží pro zpracovávání a vyhodnocování regulárních výrazů. Jako jediná z těchto knihoven může existovat plně nezávisle na ostatních knihovnách, jelikož neobsahuje závislost na žádné z dalších knihoven. Druhou knihovnou je **visualizační**, která slouží pro samotné zobrazení zpracovávaných regulárních výrazů. Jedná se o komponentu, která může být spuštěná mimo rozšíření vscode, například ve webovém prostředí. Tato knihovna obsahuje závislost na Regexer, ale na vscode extension není přímá závislost, jelikož pokud není nalezená funkce pro zasílání zpráv, tak je v rámci vizualizace ignorována. Poslední částí je samotné **rozšíření**, které se stará o komunikaci s API vscode a o řízení všeho co se týká rozšíření. Tato část aplikace implementuje vizualizační knihovnu v podobě web view (webové zobrazení).

Na obrázku 3.1 je viditelná závislost mezi knihovnami. Rovněž je patrná základní struktura těchto knihoven a jejich závislosti mezi sebou. Avšak jsou zakresleny jen ty komponenty, které můžeme považovat za nejdůležitější. Je dobré zdůraznit asynchroní komunikaci, kterou poskytuje knihovna regexer (vyhodnocující regexy). Tuto komunikaci lze vidět mezi komponentou Regexer a RegexVisualizer s tím, že Regexer využívá vedlejší vlákno mimo hlavní. Knihovna pro vlákna threads.js je popsána v sekci 3.2.







Obrázek 3.2: Příklad výsledné JSON struktury regulárního výrazu  $a^+$

## 3.2 Použité technologie

Tato aplikace je integrovaná do vývojového prostředí **visual studio code**, zkráceně **vscode**. Jádru aplikace je psáno v programovacím jazyce **TypeScript**, zkráceně **TS** verze 5.3, který je nadvýstavbou pro jazyk **JavaScript**, zkráceně **JS**. TypeScript, jak z názvu vyplývá je typový JavaScript. Každý kód napsaný v JS je správný pro TS, ale to neplatí naopak. Psaní nějaké větší aplikace je tak vhodnější v TS, kvůli svým typovým kontrolám, čímž se můžeme vyhnout potenciálním chybám v běhu programu. Také vyvíjení rozšíření pro vscode, je možné pouze v JavaScriptu nebo TypeScriptu.

Pro parsování je použita bezkontextová gramatika **Peggy**[8, 9], pro jazyk JavaScript. Ta umožňuje poměrně snadné zpracování textové podoby regulárních výrazů do podoby strukturované. Tato výsledná struktura může být v podstatě jakákoliv.

Části aplikace jsou spravovány balíčkovým manažerem **NPM** (Node Package Manager). Využívají tedy balíčků, které jsou dostupné pro npm. Aplikace je pak postavená na technologii **NodeJS**, jedná se o JavaScript runtime (běh programu). Runtime **vscode** rozšíření je totiž **NodeJS**, ale samotné web view běží na klasickém webovém runtime, které je typické pro webové prohlížeče.

Visualizační část aplikace pak využívá základní **HTML** struktury. HTML je základem pro webové stránky a definuje jejich strukturu pomocí značek. Pro následné stylování, je využito technologie **LESS**, což je rozšíření standartního **CSS**. Avšak LESS musí být transpilovaný<sup>6</sup> do CSS,

<sup>6</sup>Typ překladu z jednoho jazyka na jazyk jiný

jelikož webová stránka ho nezná. LESS umožňuje, například vnořování stylů nebo tvorbu vlastních proměnných. Pro logickou část vizualizační knihovny je také využit TypeScript.

Pro výsledný přeložený kód, je použit balicí nástroj **webpack**. Ten nám umožňuje, všechny části aplikace poměrně efektivně zabalit, do malého počtu souborů. Tento nástroj se pak hodí, pro menší výslednou aplikaci a hlavně pro seskupení všech závislostí. Můžeme mít i větší kontrolu nad výsledným kódem. Například můžeme udávat kdy se mají soubory dělit, jak se mají zpracovávat přílohy, jako jsou obrázky atd. Pro optimalizaci a úpravu kódu, se zde využívá takzvaných **loaderů** a **pluginů**, které dokážou v určité části překladače zasáhnout a popřípadě změnit určitou část kódu. Ve výsledku se jedná o velice silný nástroj, který dává programátorovi větší kontrolu nad výsledným přeloženým kódem aplikace.

Jelikož chceme mít větší jistotu správnosti aplikace, je v logické části aplikace využito technologie pro tvorbu testů. Tato knihovna se nazývá **Jest**, protože je tato knihovna převážně pro testování JavaScriptových kódů, tak je s ní využito pro TypeScriptové soubory **ts-jest**. To nám pak umožňuje psát testy určené i pro typovost TS.

Jednou z posledních knihoven, která je použita je **threads.js**. Jelikož existují různé runtime JavaScriptu, tak neexistuje jednotné využití vláken (threadů). Browser má tzv. **web workery** a NodeJS má **worker thready**, sice si jsou podobné, ale mají změny které znemožňují univerzálního použití. Proto je v této aplikaci využito knihovny threads.js, která eliminuje tyto problémy. Navíc dokáže zpřístupnit větší bezpečnost pro programátora, který píše kód v TS. Tato bezpečnost je docílená tím, že knihovna umožňuje poskytnout z vlákna rozhraní, které může obsahovat i typy. Základní funkcionalitu knihovny threads.js lze vidět, v ukázce zdrojového kódu 3.1.

---

```
/* ----- Hlavní vlákno ----- */
/* Zavolání metody workera z rodiče */
await this.worker_?.match(pid, matchString, options?.batchSize ?? -1);

/* ----- Worker ----- */
const Matcher = {
  match(pid : number, matchString : string, batchSize: number = -1) :
  ReturnMatch | ReturnBatch | ReturnAborted | null
  {
    // logika funkce
  }
}
expose(Matcher); /* Zviditelnění objektu Matcher pro rodiče */
```

---

Zdrojový kód 3.1: Příklad použití knihovny threads.js

Workery v JS, jsou limitovány tím, že komunikace mezi hlavním a vedlejším vláknem, probíhá formou zpráv. Demonstraci této komunikace lze vidět ve zdrojovém kódu 3.2. U přijmutých zpráv nemůžeme zjistit před během programu, co nám z vlákna přijde za odpověď. Na to si programátoři, musí dávat pozor, aby předešli chybám, které mohou nastat při běhu programu. Knihovna threads.js sice na pozadí volá buď worker thread nebo web worker, podle prostředí ve kterém běží, ale poskytuje rozhraní, které je programátorsky přijatelnější.

---

```
/* ----- Hlavní vlákno ----- */
/* posílání zprávy do workeru */
myWorker.postMessage({type: "match", pid, matchString, batchSize});

myWorker.onmessage = (event : MessageEvent)
{
    // event.data má typ any (neznámý), jedná se o poslanou proměnnou message
    // kontrola dat například pomocí switche
}

/* ----- Worker ----- */
onmessage = (event : MessageEvent) => {
    // stejná situace, která je u hlavního vlákna onmessage

    /* posílání zprávy zpět do hlavního vlákna */
    parentPort.postMessage(message);
}
```

---

Zdrojový kód 3.2: Příklad použití web workeru a posílání zpráv

## Kapitola 4

# Knihovna pro práci s regulárními výrazy

Jako prvotní myšlenka před tvorbou samotné vizualizace, jsem měl úvahu o použití knihovny, která by mi umožňovala zpracovávat regulární výrazy. Sice implementace regulárních výrazů se nachází v samotné specifikaci JavaScriptu, ale ta mi neumožňuje získat informaci o samotném vyhledávání. Po prozkoumání, zda-li existují řešení, která by vyhovovala této práci, jsem uznal za vhodné, vytvořit vlastní implementaci v podobě této knihovny. Nenaleznul jsem totiž řešení, které by bylo dostatečně flexibilní a zároveň lehce integrovatelné do programovacího jazyku TypeScript. Sice vlastní implementace je pracná, ale jelikož chci mít co nejvyšší kontrolu nad výslednou strukturou, tak je toto řešení pro tuto aplikaci asi nejvhodnější.

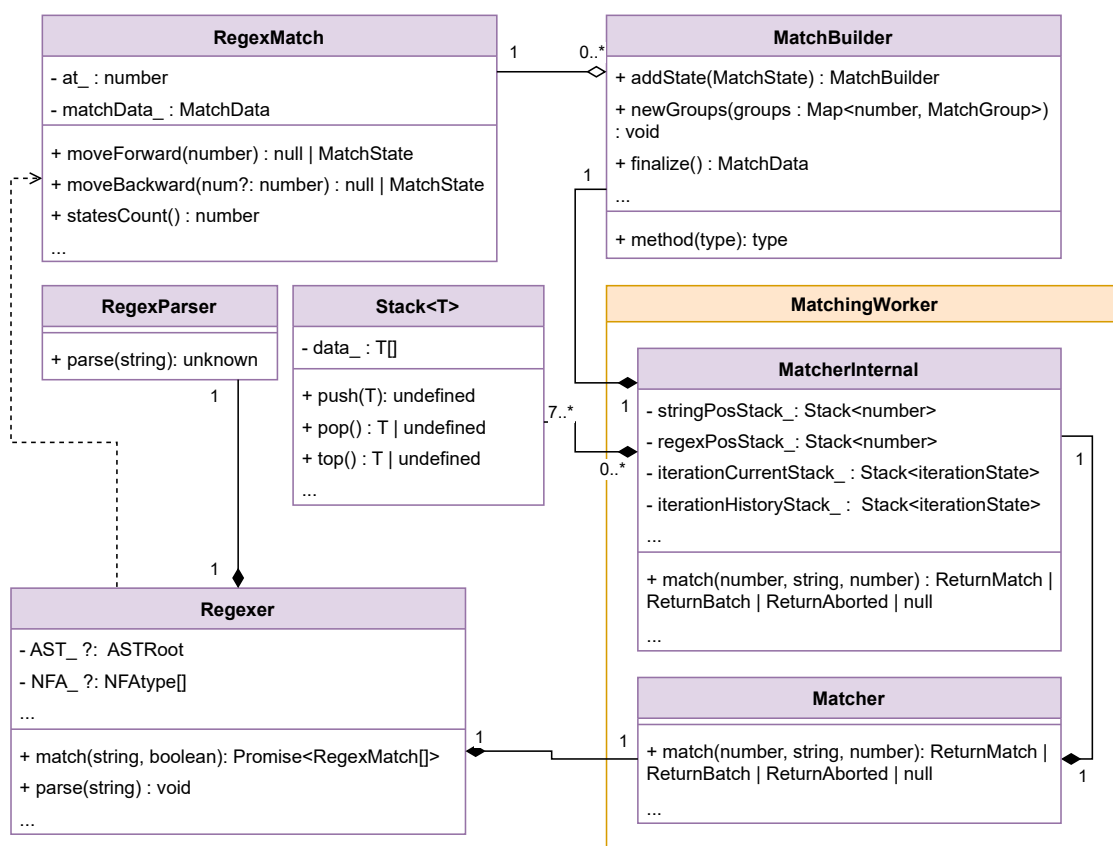
V této části práce se pokusím vysvětlit, jak je naimplementována tato knihovna 4.1, jaké problémy se ukázali při vývoji a její výhody a nevýhody.

### 4.1 Rozvržení a realizace

Vstupní třídou, pro tuto knihovnu je **Regexer**. Slouží jako spojující a zároveň obsluhující třída. Zároveň poskytuje rozhraní této knihovny. Dále si drží důležité informace, které souvisí s aktuálním regulárním výrazem. **RegexMatch** je třída, jejíž instance je výsledkem vyhledávání zadaným výrazem. Její data jsou soukromá, ale umožňuje je procházet pomocí svých metod. Jedna instance této třídy, je ekvivalentní jednomu vyhledání v textu. Data této třídy jsou generována třídou **MatchBuilder**. Instance této třídy existuje jen ve chvíli, kdy probíhá vyhledávání v zadaném řetězci. Poskytuje rozhraní, které umožňuje přidávat stavy, s tím že může s těmito daty manipulovat. Tento objekt je pak držen v třídě **MatcherInternal**, která má za úkol, průchod zadaným řetězcem, pro konkrétní výraz. Tato třída, je izolována a není dostupná z vnější, jak její jméno (internal) napovídá. Obsahuje hlavní logickou část průchodu nedeterministickým automatem. Naopak třídou, která poskytuje vyditelné rozhraní a volá metody třídy **MatcherInternal** je **Matcher**. Její rozhraní je poskytováno třídě **Regexer**. Jako poslední struktura, která stojí za zmínku, je **Stack**. Stack neboli zásobník, je velmi důležitou součástí vyhledávání. Zásobník je totiž struktura, která mi dovolu

se zbavit rekurzivního volání funkce. Rekurse obecně vede k pomalejšímu chodu programu a nelze ji jednoduše pozastavit v jakémkoliv čase. Sice rozhraní pole v JS je připraveno na funkcionalitu zásobníku, ale nezaručuje programátorovi daná pravidla pro zásobník. Z tohoto důvodu jsem zvolil jednoduchou implementaci zásobníku, která omezuje manipulaci s základním polem, na operace určené pro zásobník.

Vztahy mezi jednotlivými třídami, lze vidět na obrázku 4.1. Myslím si že je vhodné poukázat na obalující blok **MatchingWorker**. Jedná se o vstupní soubor vedlejšího vlákna, který slouží pro asynchronní komunikaci s hlavním vláknem.



Obrázek 4.1: Třídní diagram části knihovny pro práci s regulárními výrazy

## Parser regulárních výrazů

Jak již bylo zmíněno, pro parsování regulárních výrazu jsem použil bezkontextovou gramatiku Peggy. Jedná se o pokračování projektu pegjs, ale ten se již dlouho nevyvíjí. Jelikož tato knihovna je stále aktualizována a má velkou podporu vývojářů, tak jsem zvolil její využití pro tuto práci.

## Využití vlákna pro vyhledávání

Nedílnou součástí této knihovny je **paralelní zpracování** v podobě balíčku threads.js. Balíček byl již zmíněn v kapitole 3.2. Toto využití nám dovoluje složité operace přesunout tak, aby hlavní vlákno nebylo zatíženo. Vlákna nám sice umožňují efektivnější rozložení náročných programů, ale také mají svá úskalí.

JavaScript je standartně vykonáván na jediném vlákně a tak neexistuje stejné více vláknové programování, jako v jiných jazycích. Jelikož chci docílit podobného výsledku, musím spustit paralelní program, který komunikuje s hlavním vláknem, pomocí zpráv.

S volbou vývojového prostředí vscode, byla nutnost splnit podmínky stanovené pro práci s web workery, v souladu s jejich API. Podmínkou totiž je, nutnost mít zdrojový kód workeru přímo vložený ve zdrojovém kódu hlavního vlákna. To znamená, že worker nesmí být přímo načítaný, z adresáře rozšíření. Avšak tato nutnost, je komplikovaná a proto následovně vysvětlím, jak jsem tento problém řešil. Všechny závislosti, které worker má musí být součástí jednoho výsledného souboru. To je docíleno tím, že přeložím soubor pomocí webpacku, který vytvoří jeden výsledný soubor. Pokud by chtěl někdo využít této knihovny, v rámci prostředí NodeJS nebo Prohlížeče, tak tento překlad probíhá dvakrát pro obě prostředí. Tento soubor může následně být vložen přímo do zdrojového kódu. Pokud prostředí, které využívá tuto knihovnu má webpack, může využít loaderu, který jsem pro tuto knihovnu napsal. Ten dokáže v místě kde je worker volaný, vložit jeho zdrojový kód, v rámci textového řetězce. Výsledkem je worker, který je vložený ve zdrojovém kóde hlavního vlákna.

# Literatura

1. DIB, Firas. *Build, test, and debug regex* [online]. [B.r.]. [cit. 2024-01-25]. Dostupné z: <https://regex101.com/>.
2. AVALLONE, Jeff [online]. [B.r.]. [cit. 2024-01-25]. Dostupné z: <https://regexper.com/>.
3. [online]. [B.r.]. [cit. 2024-01-25]. Dostupné z: <https://regexr.com/>.
4. [online]. Wikimedia Foundation, 2024 [cit. 2024-02-20]. Dostupné z: [https://en.wikipedia.org/wiki/Regular\\_expression](https://en.wikipedia.org/wiki/Regular_expression).
5. HAVRLANT, Lukáš. *Konečný Automat* [online]. [B.r.]. [cit. 2024-02-06]. Dostupné z: <https://www.matweb.cz/konecny-automat/>.
6. ČERNÁ, Ivana; KŘETÍNSKÝ, Mojmír; KUČERA, Antonín. *Automaty a formální jazyky I - FI MUNI* [online]. [B.r.]. [cit. 2024-02-25]. Dostupné z: [https://www.fi.muni.cz/usr/kretinsky/afj\\_I.pdf](https://www.fi.muni.cz/usr/kretinsky/afj_I.pdf). Dis. pr.
7. [online]. Wikimedia Foundation, 2023 [cit. 2024-02-17]. Dostupné z: [https://en.wikipedia.org/wiki/Thompson%27s\\_construction](https://en.wikipedia.org/wiki/Thompson%27s_construction).
8. [online]. [B.r.]. [cit. 2024-02-25]. Dostupné z: <https://peggyjs.org/>.
9. *Peggyjs/peggy: Peggy: Parser generator for JavaScript* [online]. [B.r.]. [cit. 2024-02-25]. Dostupné z: <https://github.com/peggyjs/peggy>.